DOSSIÊ TÉCNICO DE ENGENHARIA DE DADOS

SoundGraph — Recomendação em Grafos com Neo4j

Arquitetura de dados, modelagem Cypher e motor de recomendação explicável para ecossistema musical.

PROJETO	TECNOLOGIA	AUTOR	CONTEXTO
SoundGraph Neo4j	Neo4j 5.x / Cypher	Rafael Ornelas Tozato	Projeto de Dados DIO

1. Sumário Executivo

Este dossiê especifica a modelagem e a implementação de um motor de recomendação de músicas baseado em bancos de dados em grafos. A solução supera as limitações de alta latência e junções pesadas (JOINs) do modelo relacional ao tratar conexões de consumo como entidades nativas. O sistema calcula pontuações transparentes baseadas em vizinhança de gostos e métricas de reprodução.

2. Arquitetura de Dados e Grafo de Domínio

A estrutura de dados é composta por 4 rótulos principais e 3 tipos de relacionamentos direcionados e enriquecidos com propriedades computáveis:

Elemento	Tipo / Label	Propriedades / Atributos	Descrição de Negócio
Nó	`:Usuario`	id, nome, pais	Entidade consumidora de conteúdo.
Nó	`:Musica`	id, titulo, ano, popularidade	Item do catálogo disponível para consumo.
Nó	`:Artista`	id, nome	Autor/Criador das faixas musicais.
Nó	`:Genero`	nome	Classificação categórica da música.
Aresta	`:OUVIU`	reproducoes, nota, ultimaVez	Histórico de escuta e avaliação do usuário.
Aresta	`:CRIADA_POR`	—	Vínculo de autoria entre música e artista.
Aresta	`:PERTENCE_A`	—	Pertencimento categórico ao gênero.

3. Lógica do Algoritmo de Recomendação Explicável

A consulta em linguagem Cypher realiza uma filtragem colaborativa baseada em grafos em quatro etapas encadeadas:

```
MATCH (u:Usuario {id: $idUsuario})-[r1:OUVIU]->(m:Musica)<-[r2:OUVIU]-(outro:Usuario)
MATCH (outro)-[r3:OUVIU]->(rec:Musica) WHERE NOT (u)-[:OUVIU]->(rec) WITH rec,
count(DISTINCT outro) AS usuariosSemelhantes, avg(r3.nota) AS mediaNota RETURN
rec.titulo AS Musica, usuariosSemelhantes, mediaNota, (usuariosSemelhantes * 2.0) +
(mediaNota * 1.5) AS ScoreRecomendacao ORDER BY ScoreRecomendacao DESC LIMIT 5
```

> **Vantagem de Negócio:** A abordagem não é "caixa-preta". O resultado indica exatamente a quantidade de ouvintes com perfil similar que consumiram a faixa e a nota média atribuída por eles.

4. Diretrizes de Segurança, Qualidade e Governança

- **Idempotência:** Todas as inserções utilizam a cláusula `MERGE` acompanhada de restrições de unicidade (`CONSTRAINT`) no Cypher.
- **Proteção de Credenciais:** Nenhum segredo ou chave de acesso de instâncias Neo4j Aura é versionado.
- **Conformidade LGPD:** Os dados contidos nos arquivos CSV de carga são 100% sintéticos e simulados.